

2026年度

機械学習演習

第5回：分類②（サポートベクターマシン／機械学習I に相当）

計良 宥志

本日の内容

1. 線形分類器の復習と「良い分類境界」とは何か
2. サポートベクターマシン (SVM) : マージン最大化のアイデア
3. ハードマージンとソフトマージン (ヒンジロス)
4. 演習1 : ソフトマージンSVMを勾配法で実装
5. 線形分離できないデータと特徴抽出
6. 演習2 : 非線形データへの拡張
7. 双対問題とカーネル : SVMの別視点

1. SVM とマージン最大化

分類の設定（復習）

データ

m 個のサンプル $\{(x_i, y_i)\}_{i=1}^m$, $x_i \in \mathbb{R}^n$, $y_i \in \{-1, +1\}$

線形分類器

線形モデル $f(x) = w^\top x + b$ の**符号**でラベルを決める.

$$\hat{y} = \text{sign}(w^\top x + b)$$


正しく分類できているとは？

y_i と $w^\top x_i + b$ が**同符号**. つまり $y_i(w^\top x_i + b) > 0$.
(あとで $y_i(w^\top x_i + b)$ がロスの基本量として登場する)

サポートベクターマシン

複数の分類器が訓練データを正しく分けるとき，どれを選ぶべきか？

アイディア：境界から一番近いデータ点までの距離が大きい境界が良さそう。
多少データが揺れても正しく分類できる安定な境界になる。



マージン：分類境界 $w^\top x + b = 0$ と，最も近いデータ点との距離。

ハードマージンSVMの定式化

訓練データが**線形分離可能**であると仮定し、マージンを最大化する.

$$\max_{w,b} \frac{1}{\|w\|} \min_i y_i(w^\top x_i + b)$$

最も近い点で $y_i(w^\top x_i + b) = 1$ となるようにスケールを取ると、以下と等価.

$$\min_{w,b} \frac{1}{2} \|w\|^2 \quad \text{s.t.} \quad y_i(w^\top x_i + b) \geq 1 \quad (i = 1, \dots, m)$$

解法：目的関数が二次・制約が線形の**二次計画問題 (QP)**.

専用ソルバー（`cvxpy`，`scipy.optimize` など）で解ける.

ヒンジロスとソフトマージン

実データには外れ値もあり，制約 $y_i(w^\top x_i + b) \geq 1$ は厳しすぎることが多い.
→ 制約違反を**罰金**として目的関数に組み込む.

ヒンジロス (一つの点での違反量)

$$\ell_{\text{hinge}}(z) = \max(0, 1 - z), \quad z = y_i(w^\top x_i + b)$$

ソフトマージンSVM

$$\mathcal{L}(w, b) = \frac{1}{2} \|w\|^2 + C \sum_{i=1}^m \max(0, 1 - y_i(w^\top x_i + b))$$

最適化方針：勾配降下法で $\mathcal{L}$ を最小化する.

$$(w, b) \leftarrow (w, b) - \eta \nabla \mathcal{L}(w, b)$$

演習（勾配を求めよう）

ソフトマージンSVMのロス

$$\mathcal{L}(w, b) = \frac{1}{2} \|w\|^2 + C \sum_{i=1}^m \max(0, 1 - y_i(w^\top x_i + b))$$

勾配 $\nabla_w \mathcal{L}(w, b)$, $\nabla_b \mathcal{L}(w, b)$ を求めよ.

2. 演習1：ソフトマージンSVMの実装

演習1：ソフトマージンSVMで二値分類

二つのクラスを、**自前で書いた勾配法**で分類する.

Step 1 (データ生成) 平均 0 ・分散 1 の二次元ガウス分布 $\mathcal{N}(0, I_2)$ からサンプリングし,

- $(1, 1)$ だけシフトしたものを **クラス +1**
- $(-1, 1)$ だけシフトしたものを **クラス -1**

Step 2 (ロス関数) データ $\{(x_i, y_i)\}$, 重み (w, b) , ハイパーパラメータ C を引数に, ソフトマージンロス $\mathcal{L}(w, b)$ を返す関数 `soft_margin_loss` を作れ.

Step 3 (勾配) 同じ引数で, 勾配 $\nabla_w \mathcal{L}$, $\nabla_b \mathcal{L}$ を返す関数 `soft_margin_loss_grad` を作れ.

演習1（続き）

Step 4（勾配法） `soft_margin_loss_grad` を使って、最適な (w, b) を勾配降下法で求めるコードを書け.

$$w \leftarrow w - \eta \nabla_w \mathcal{L}, \quad b \leftarrow b - \eta \nabla_b \mathcal{L}$$

Step 5（可視化）

- **損失曲線**：横軸が勾配法の反復回数，縦軸が損失 $\mathcal{L}$ のグラフ.
- **境界の推移**：訓練中の**初期・中期・最終**で (w, b) を保存しておき，3本の分類境界をデータ点とともに重ねてプロット.

3. 線形分離できないデータと特徴抽出

「線形」とは？

「線形制約式」「線形分類器」「線形回帰」… この「線形」とは何だったか？

定義（線形写像）



関数 $f: \mathbb{R}^m \rightarrow \mathbb{R}^n$ が**線形**であるとは、任意の $x, y \in \mathbb{R}^m$ と $\alpha, \beta \in \mathbb{R}$ について以下が成り立つこと.

$$f(\alpha x + \beta y) = \alpha f(x) + \beta f(y)$$

例： $f(x) = Ax$ は線形. $f(x) = Ax + b$ ($b \neq 0$) は**アフィン**で、厳密には線形ではない.

イメージ：「足し算とスカラー倍が中と外で交換できる」 = 「直線が直線に写る」

線形分離可能なデータとは？



左：二重同心円のデータ。直線では分けられない（線形分離不可能）。
右：適切な特徴抽出後の空間。直線で分けられる（線形分離可能）。

特徴抽出

特徴抽出関数 $\phi : \mathbb{R}^n \rightarrow \mathbb{R}^D$ を導入し, x の代わりに $\phi(x)$ を使う.

ハードマージンSVM (特徴抽出版)

$$\min_{w,b} \frac{1}{2} \|w\|^2 \quad \text{s.t.} \quad y_i (w^\top \phi(x_i) + b) \geq 1 \quad (i = 1, \dots, m)$$

ここで重み $w \in \mathbb{R}^D$ は**特徴空間側**のベクトル.

例 : $\phi(x) = (x_1, x_2, x_1^2 + x_2^2)$ と取れば, 二重同心円のデータも特徴空間では線形分離可能になる.

演習2：特徴抽出＋ソフトマージンSVM

Step 1（データ生成） 二重同心円のデータを作る．内側を **クラス +1**，外側を **クラス -1**．

Step 2（特徴抽出） 線形分離可能になる基底関数 $\phi(x)$ を定義せよ．

Step 3～5（学習） 演習1と同様に，

- $\phi(x)$ に対して ソフトマージンのロス・勾配を実装
- 勾配法で (w, b) を学習
- 損失曲線をプロット

Step 6（可視化） 分類境界は**元の空間**（ ϕ を適用する前の $\mathbb{R}^2$ ）で描く．

グリッド上の各点 x で $\text{sign}(w^\top \phi(x) + b)$ を計算して塗り分ければよい．

4. SVM の別視点：双対問題

双対問題というアイデア

これまで：目的関数 $\mathcal{L}(w, b)$ を**直接**最小化していた（主問題）.

双対問題： $\mathcal{L}$ の**下界**を与える関数 $g(\alpha)$ を**最大化**する問題.

$$\min_{w, b} \mathcal{L}(w, b) \quad \longleftrightarrow \quad \max_{\alpha \geq 0} g(\alpha)$$

- ある条件のもとで、主問題の最適化と双対問題の最適化は同じ結果を与える.
- **嬉しさ**：双対問題を考えると、主問題からは見えにくい**新しい視点**や**効率的な解法**が現れることがある.

双対問題からわかること（SVM編）

SVMの双対問題を導くと、最適な重み w が訓練データの線形和で書けることが分かる。

$$w = \sum_{i=1}^m \alpha_i y_i \phi(x_i) \quad (\alpha_i \geq 0)$$

このとき新しい点 x に対する予測は

$$w^\top \phi(x) + b = \sum_{i=1}^m \alpha_i y_i \phi(x_i)^\top \phi(x) + b$$

発見： ϕ 自体ではなく、**内積** $\phi(x_i)^\top \phi(x)$ さえ計算できればよい。

カーネルトリック

- **カーネルトリック**：カーネル関数 K を使って内積計算をサボる技術
- $\phi(x) \in \mathbb{R}^D$ を陽に計算するコストは $O(D)$. 高次元になると計算が重い.
- SVM では, ϕ を経由せず内積 $\phi(x)^\top \phi(x') =: K(x, x')$ だけ知っていれば学習も予測もできる.
- この $K(x, x')$ を**カーネル関数**と呼ぶ.

例： d 次多項式カーネル

$$K(x, x') = (x^\top x' + c)^d$$

- 対応する ϕ は $\mathbb{R}^n$ から見ると**非常に高次元** ($\binom{n+d}{d}$ 次元) だが, $K(x, x')$ 自体は $O(n)$ で計算できる.

双対問題とは何か？

主問題：目的関数の最小化（以下は特徴抽出 ϕ なしの場合）

$$\min_{w,b} \frac{1}{2} \|w\|^2 \quad \text{s.t.} \quad y_i(w^\top x_i + b) \geq 1 \quad (i = 1, \dots, m)$$

双対問題：目的関数の下界の最大化

制約付き最適化問題 → ラグランジュ関数を経由した下界.

SVMのロスの下界（ラグランジュ関数）

ラグランジュ関数 ($\alpha = \{\alpha_i\}_i$ とかく)

$$L(w, b, \alpha) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^m \alpha_i (y_i (w^\top x_i + b) - 1), \quad \alpha_i \geq 0.$$

- 制約が満たされているような w, b に対して $L(w, b, \alpha) \leq 1/2 \|w\|^2$.
- 左辺 $L(w, b, \alpha)$ から w, b を消せば楽 ($\rightarrow$ 下界 $g(\alpha)$ の登場).

$$g(\{\alpha_i\}_i) = \min_{w, b} L(w, b, \alpha) \quad (\text{常に } \leq \frac{1}{2} \|w\|^2)$$

- 双対問題：下界 $g(\alpha)$ に $\alpha_i \geq 0$ に関して最大化
- 事実：ある条件のもとで，主問題と双対問題の解は一致する.

SVMの双対問題（具体形）

$g(\alpha) = \min_{w,b} L(w, b, \alpha)$ を実際に計算してみる.


最小化条件 : $\partial L / \partial w = 0, \partial L / \partial b = 0$ を解いて

$$w = \sum_{i=1}^m \alpha_i y_i x_i, \quad \sum_{i=1}^m \alpha_i y_i = 0$$

これを L に代入すると (w が α で書けたので L は α だけの式に)

$$g(\alpha) = \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j x_i^\top x_j$$

イメージ図



SVMの双対問題

$$\max_{\alpha \geq 0} \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j x_i^\top x_j \quad \text{s.t.} \quad \sum_i \alpha_i y_i = 0$$

- 期待通り, w は訓練データの線形和 (→ 前述).
- 双対問題には**内積** $x_i^\top x_j$ **しか登場しない** → カーネル $K(x_i, x_j)$ に置き換えれば非線形にも対応.

