

2026年度

機械学習演習

第6回：分類③（決定木／機械学習I に相当）

計良 宥志


本日の内容

1. 分類は領域分割という視点の復習
2. 決定木：Yes/No ルールによる解釈可能な領域分割
3. 決定木アルゴリズムの概要
4. コア問題：2分割の方法と「良い分割」とは何か
5. 不純度関数：Gini 不純度・エントロピー
6. 演習：決定木の実装


1. 分類と決定木

分類


- いい感じの分類境界を引きたい = **領域分割**をしたい
- **線形2クラス分類** = 領域を2分割
- **(一般) 多クラス分類** = 領域を多分割 (分割数 $\neq$ 領域数 であることに注意！)
- **複雑な分割** = 解釈性の低下



(a) linear 2-class




(b) multi-class split



(c) complex (less interpretable)

決定木：複雑だが**解釈可能**な領域分割を実現


Akinator



<https://jp.akinator.com/>

決定木のアイデア

Idea : 分類するための Yes/No ルール (の繰り返し)



要は, **2分割を繰り返す**ことで領域を細かく分けていく.

決定木のアルゴリズム（概要）

設定： K クラス分類. 学習データ $S = \{(x_1, y_1), \dots, (x_m, y_m)\}$

Step 1 S をある特徴 x_j に着目し, 適当な閾値 s で2つに分割する.

$$S^1 = \{(x, y) \in S \mid x_j \leq s\}, \quad S^2 = \{(x, y) \in S \mid x_j > s\}$$

Step 2 以降 分割結果 S^i について, (以前と同じとは限らない) ある特徴 x_j と閾値 s で 2 つに分割する. これを**繰り返す**.

最終状態 学習データが重複なく分割され, 木構造の葉に紐づく.

$$S = S_1 \cup S_2 \cup \dots \cup S_r \quad (S_k \cap S_{k'} = \emptyset)$$

決定木による予測

予測：入力 x がどの葉 S_k に属するかを、木をルートから辿って決定する。

S_k のラベル比率がそのまま x のクラス確率になる。

$$p(c \mid x) = \frac{|\{(x', y') \in S_k \mid y' = c\}|}{|S_k|}$$

最後は多数決： $\hat{y}(x) = \arg \max_c p(c \mid x)$.

コアな問題：いま S があったとき、これを**どう2分割するか**？

2. 良い分割とは何か

コア問題：2分割の方法

サンプル集合 $S = \{(x_i, y_i)\}_{i=1}^m$ をどう2分割するか？

「良い分割」への直感的な要請

一つの分割（部分集合）には，なるべく**同クラスが集まって欲しい**。

これを**関数として定式化**できれば，分割の良さを数値で比較できる。

演習（「良い分割」の具体化）

サンプル集合 $S = \{(x_1, y_1), \dots, (x_m, y_m)\}$ の「良い分割」への直感

一つの分割には、なるべく**同じクラスのもの**だけがまとまってほしい。


この直感を実現する関数 ℓ を**2種類**考えてみよ。

ヒント

1. そもそも ℓ は何の関数になるだろうか？（定義域と値域は？）
2. まずは2クラス分類（クラス 0 とクラス 1）から考える
3. ℓ の値を縦軸，クラス 0 の割合 p を横軸にしたプロットはどんな形になってほしい？

不純度関数（「分割の悪さ」を与える関数）

ℓ は、部分集合 S' の「不純度」（クラスの混ざり具合）を測る関数. 2クラス分類でクラス 0 の割合を p とすると：



$p = 0, 1$ で $\ell = 0$, $p = 0.5$ で最大 → 凸で対称な関数.

代表的な不純度関数

部分集合 S' におけるクラス c の割合を $p_c = |\{(x, y) \in S' \mid y = c\}| / |S'|$ とする.

Gini 不純度

$$\ell_{\text{Gini}}(S') = 1 - \sum_{c=1}^K p_c^2 \quad (2 \text{ クラス} : 2p(1-p))$$

エントロピー (情報量)

$$\ell_{\text{Ent}}(S') = - \sum_{c=1}^K p_c \log_2 p_c \quad (2 \text{ クラス} : -p \log_2 p - (1-p) \log_2 (1-p))$$

どちらも**「混ざっているほど大」「片寄っているほど小」**を測る凸対称な関数.

不純度関数を分割に使う

分割の良さは、**分割前の不純度**から**分割後の重み付き平均**をどれだけ減らせるかで測る.

$$\Delta = \ell(S) - \frac{|S^1|}{|S|} \ell(S^1) - \frac{|S^2|}{|S|} \ell(S^2)$$

決定木の学習アルゴリズム：各ノードで、全特徴 x_j と全閾値 s について試し、情報利得が最大の分割を選ぶ.

$$(j^*, s^*) = \arg \max_{j, s} \left[\ell(S) - \frac{|S^1|}{|S|} \ell(S^1) - \frac{|S^2|}{|S|} \ell(S^2) \right]$$

停止条件（過学習を防ぐため必要）：ノードのサンプル数下限／木の深さ上限／不純度ゼロなど.

3. 演習：決定木の実装

演習：決定木の実装

雛形 `src/decision_tree.py` の `# TODO` を埋めて完成させよ.

Step 1 (データ生成) 2クラス分類用の2次元データを作る. 以下のいずれかでよい.

- `sklearn.datasets.make_moons` / `make_circles` / `make_classification`
- 適当な 2 つのガウス分布からサンプリング

Step 2 (不純度関数) ラベル配列 `y` から Gini 不純度 (またはエントロピー) を返す `_gini(y)` / `_entropy(y)` を実装せよ.

演習（続き）

Step 3（最良分割） `_best_split(X, y)` を実装せよ.

データ (X, y) について**情報利得**が最大となる**特徴 j** と**閾値 s** （および利得）を返す.

Step 4（木の構築） `_build_tree(X, y, depth)` を**再帰的に**実装せよ.

`_best_split` を呼んで子ノードを作り, **最大深さ** `self.max_depth` 等で停止する. 戻り値は `Node` の根. `fit` から `depth=0` で呼ばれる.

演習（続き）

Step 5（予測） `_predict_one(x)` を実装せよ.

学習済みの木 `self.root` を根として, $x_{\text{feature_id}} \leq \text{threshold}$ で `left` / `right` に降りていき, 葉に到達したら `label` を返す.

Step 6（可視化）

- 学習データの散布図に**決定境界**を重ねてプロットせよ.
- `max_depth` を変えて境界がどう変わるか確認（過学習の様子が見えるはず）.

課題

- 演習（決定木の実装）を Moodle で提出（IPython Notebook 形式）.

発展課題（任意）

- `sklearn.tree.DecisionTreeClassifier` の結果と比較する.
- `max_depth` を変えて訓練誤差・テスト誤差をプロット（過学習の確認）.
- 不純度関数を Gini とエントロピーで切り替え，結果に差が出るか比較する.

