

2026年度

機械学習演習

第7回：学習問題の「難しさ」と PAC 学習

計良 宥志

本日の内容

1. ****学習問題の「難しさ」**とは何か**
2. **PAC 学習**による学習問題の定式化
3. 重要なキーワードの解説
 - 仮説集合 $\mathcal{H}$
 - 汎化誤差と訓練誤差
 - サンプル複雑度
 - Rademacher 複雑度
4. **演習**：線形二値分類器の Rademacher 複雑度の計算

1. 学習問題の「難しさ」とは？

学習問題の「難しさ」とは？

計算問題：「難しさ」は**時間計算量・空間計算量**で定量化される。


- 問題の難しさ = それを解くのに（最低限）必要な計算コスト.
- アルゴリズムの良さも同じ尺度で測れる.

ある**学習問題**の「難しさ」は、どのように表現すればいいだろうか？


直感的には、例えば次のような差がある：

- **データ側**：離れた 2 つの正規分布 → **簡単** / 二重同心円 → **難しい**.
- **モデル側**：線形分類器の訓練 → **簡単** / 大規模深層モデル → **難しい**.

例：データ側の難しさ



(a) easy: well-separated



(b) hard: concentric rings

- (a) は直線（線形分類器）で分けられる：少ないデータでも汎化しそう.
- (b) は直線では分けられない：より柔軟なモデル+より多くのデータが必要.

2. 学習問題の定式化：PAC 学習

学習の構成要素

- 入力空間 $\mathcal{X}$, 出力空間 $\mathcal{Y}$ (例: $\mathcal{Y} = \{0, 1\}$)
- 未知の分布 $\mathcal{D}$ ($\mathcal{X} \times \mathcal{Y}$ 上の同時分布)
- 訓練データ $S = \{(x_i, y_i)\}_{i=1}^m \sim \mathcal{D}^m$ (i.i.d.)
- 仮説集合 $\mathcal{H} : h : \mathcal{X} \rightarrow \mathcal{Y}$ の集合 (モデルが表現できる関数の全体)
 - 例 (線形分類器) : $\mathcal{H}_{\text{lin}} = \{x \mapsto \text{sign}(w^\top x + b) \mid w \in \mathbb{R}^n, b \in \mathbb{R}\}$
- 学習アルゴリズム $\mathcal{A}$: データ S から仮説 $h_S \in \mathcal{H}$ を選ぶ手続き

誤差の二つの顔

サンプル (x, y) に対する損失を $\ell(h(x), y)$ とする (例: $\ell = \mathbb{1} [h(x) \neq y]$).

汎化誤差 (真の誤差): 未知の分布 $\mathcal{D}$ 上での期待損失.

$$L_{\mathcal{D}}(h) = \mathbb{E}_{(x,y) \sim \mathcal{D}} [\ell(h(x), y)]$$

訓練誤差 (経験誤差): 手元のデータ S 上での平均損失.

$$L_S(h) = \frac{1}{m} \sum_{i=1}^m \ell(h(x_i), y_i)$$

学習の難しさ

素朴に考えた良い学習

汎化誤差 $L_{\mathcal{D}}(h) = \mathbb{E}_{(x,y) \sim \mathcal{D}}[\ell(h(x), y)]$ が小さい関数 h の発見

しかし、我々の学習設定は**有限**である.

- 有限集合 S を用いた経験誤差 $L_S(h) = \frac{1}{m} \sum_{i=1}^m \ell(h(x_i), y_i)$ の最小化
- 有限の **仮説集合 $\mathcal{H}$** (候補関数の集合)

学習が難しい (=良い学習が難しい) とは

(ある仮説集合 $\mathcal{H}$ のもとで) 汎化誤差 $L_{\mathcal{D}}(h)$ を小さくするのに大きな S が必要

PAC 学習

Probably **A**pproximately **C**orrect : たぶん, だいたい正しい.

仮説集合 $\mathcal{H}$ が **PAC 学習可能** $\stackrel{\text{def}}{\iff}$ ある学習アルゴリズム $\mathcal{A}$ と関数 $m_{\mathcal{H}}(\varepsilon, \delta)$ が存在し, 任意の $\varepsilon, \delta \in (0, 1)$, 任意の分布 $\mathcal{D}$ に対して,

$$m \geq m_{\mathcal{H}}(\varepsilon, \delta) \implies \Pr_{S \sim \mathcal{D}^m} \left[L_{\mathcal{D}}(h_S) \leq \varepsilon \right] \geq 1 - \delta$$

- ε : **Approximately** (誤差の許容度)
- $1 - \delta$: **Probably** (成功確率)

学習が難しい = サンプル複雑度 $m_{\mathcal{H}}(\varepsilon, \delta)$ が大きい.

有限仮説集合は PAC 学習可能

仮定

- **0-1 損失** $\ell(h(x), y) = \mathbb{1}[h(x) \neq y]$ ($\rightarrow L_{\mathcal{D}}(h) = \Pr[h(x) \neq y]$).
- 訓練誤差を最小化するアルゴリズム $\mathcal{A}$ (ERM) が存在する.
- 仮説集合 $\mathcal{H}$ は **有限集合** かつ **汎化誤差を0にする関数 h^* を含む** (realizable).

事実

$$m_{\mathcal{H}}(\varepsilon, \delta) \leq \frac{\log(|\mathcal{H}|/\delta)}{\varepsilon}$$

$\Rightarrow \mathcal{H}$ が有限なら PAC 学習可能. サンプル複雑度は $\log |\mathcal{H}|$ にのみ依存.

証明 (1/2) : 戦略

示したいこと : $m \geq \log(|\mathcal{H}|/\delta)/\varepsilon$ のもとで

$$\Pr_{S \sim \mathcal{D}^m} [L_{\mathcal{D}}(h_S) > \varepsilon] \leq \delta.$$

ここで $h_S = \arg \min_{h \in \mathcal{H}} L_S(h)$ (ERM). realizable なので $L_S(h_S) = 0$.

戦略 「悪い仮説」の集合を

$$\mathcal{H}_B = \{ h \in \mathcal{H} \mid L_{\mathcal{D}}(h) > \varepsilon \}$$

と定義する. ERM が悪い仮説を返すのは, $\mathcal{H}_B$ の中に**訓練誤差 0 の仮説が少なくとも 1 つある**とき. よって示すべきは :

$$\Pr [\exists h \in \mathcal{H}_B : L_S(h) = 0] \leq \delta.$$

証明 (2/2) : 和集合バウンド

Step 1 固定した $h \in \mathcal{H}_B$ について, m 個 i.i.d. なので

$$\Pr[L_S(h) = 0] = (1 - L_D(h))^m < (1 - \varepsilon)^m \leq e^{-\varepsilon m}.$$

(最後は $1 - x \leq e^{-x}$)

Step 2 $\mathcal{H}_B$ 上での和集合バウンド

$$\Pr[\exists h \in \mathcal{H}_B : L_S(h) = 0] \leq \sum_{h \in \mathcal{H}_B} \Pr[L_S(h) = 0] \leq |\mathcal{H}| e^{-\varepsilon m}.$$

Step 3 右辺を δ 以下にする m を求める :

$$|\mathcal{H}| e^{-\varepsilon m} \leq \delta \iff m \geq \frac{\log(|\mathcal{H}|/\delta)}{\varepsilon}. \quad \blacksquare$$

仮説集合と「学習可能性」

ERM（経験誤差最小化）： $h_S = \arg \min_{h \in \mathcal{H}} L_S(h)$.

我々が本当に欲しいのは $L_{\mathcal{D}}(h_S)$ の小ささだが、

$$L_{\mathcal{D}}(h_S) = \underbrace{L_S(h_S)}_{\text{訓練誤差}} + \underbrace{(L_{\mathcal{D}}(h_S) - L_S(h_S))}_{\text{汎化ギャップ}}$$

- 訓練誤差は最適化で下げられる.
- 汎化ギャップは「 $\mathcal{H}$ の複雑さ」と「データ数 m 」で決まる.

学習可能性の本質：

$\mathcal{H}$ 上で一様に $\bar{\Delta} = \sup_{h \in \mathcal{H}} |L_{\mathcal{D}}(h) - L_S(h)|$ を小さく抑えられるか.

- 任意の $h \in \mathcal{H}$ に対して、汎化誤差は $L_{\mathcal{D}}(h) \leq L_S(h) + \bar{\Delta}$ が保証される.

汎化ギャップを抑える：バイアス・バリエンス分解

直感

- $\mathcal{H}$ が複雑な関数まで含む $\Rightarrow L_{\mathcal{D}}$ を下げる候補が増える (良い).
- 同時に, L_S は小さいが $L_{\mathcal{D}}$ は大きい関数 (訓練データの雑音にフィット) も含みやすい (悪い).

バイアス・バリエンス分解

$\mathcal{H}$ における最良仮説 $h^* = \arg \min_{h \in \mathcal{H}} L_{\mathcal{D}}(h)$ に関して,

$$L_{\mathcal{D}}(h_S) = \underbrace{L_{\mathcal{D}}(h^*)}_{\text{近似誤差 (bias)}} + \underbrace{L_{\mathcal{D}}(h_S) - L_{\mathcal{D}}(h^*)}_{\text{推定誤差 (variance)}}$$

- 近似誤差： $\mathcal{H}$ がそもそも真の関数をどれだけ近似できるか ($\mathcal{H}$ の表現力で決まる).
- 推定誤差：有限サンプル S から h_S を選ぶ際のブレ ($\mathcal{H}$ の複雑さと m で決まる).

バイアス・バリエンス分解の直感

仮説集合 $\mathcal{H} = \{h_1, \dots, h_r\}$ には色々な関数が含まれている.

- 異なる関数 $h_i, h_j \in \mathcal{H}$ の振る舞いが似ている $\rightarrow$ バリエンスが低い
- ある良い関数 h^* が含まれている $\rightarrow$ バイアスが小さい

当然, 「 $\mathcal{H}$ が含むのは似たような関数ばかりで, そのどれも良い関数である」 がベスト.
しかし, 「良い関数」はタスクによって異なるので, 現実的に可能な $\mathcal{H}$ の設計には

- 「みんな揃ってみんな悪い」: high bias & low variance
- 「いいヤツも悪いヤツもいる」 low bias & high variance

というトレードオフが生じる ($\rightarrow$ バイアス・バリエンスのトレードオフ).

仮説集合の複雑さ

直感： 仮説集合 $\mathcal{H}$ が複雑（＝「いいヤツも悪いヤツもいる」）だと学習が難しい。

仮説集合の複雑度はどのように測ればいいだろうか？

- *Rademacher複雑度 $\mathfrak{R}(H)$ により定量化される
- 汎化ギャップも $\mathfrak{R}(H)$ で抑えられる。

確率 $\geq 1 - \delta$ で、 **任意の** $h \in \mathcal{H}$ に対して：

$$L_{\mathcal{D}}(h) \leq L_S(h) + 2 \hat{\mathfrak{R}}_S(\mathcal{H}) + 3 \sqrt{\frac{\log(2/\delta)}{2m}}$$

Rademacher 複雑度

Rademacher 複雑度：仮説集合の「ランダムなラベルへの当てはまりやすさ」.

訓練データ $S = \{x_1, \dots, x_m\}$, iidな確率変数 $\sigma_1, \dots, \sigma_m \sim \text{Unif}\{-1, 1\}$

$$\hat{\mathfrak{R}}_S(\mathcal{H}) = \mathbb{E}_\sigma \left[\sup_{h \in \mathcal{H}} \frac{1}{m} \sum_{i=1}^m \sigma_i h(x_i) \right]$$

- $\sigma_i h(x_i)$: 「 $h(x_i)$ の絶対値が大きいかつ符号が σ_i と一致」で大きい値
- $\hat{\mathfrak{R}}_S(\mathcal{H})$ が大: 訓練データにどんなラベルがついても, 強くalignする $h \in \mathcal{H}$ を選べる

Rademacher 複雑度による汎化バウンド

確率 $\geq 1 - \delta$ で、任意の $h \in \mathcal{H}$ に対して：

$$L_{\mathcal{D}}(h) \leq \underbrace{L_S(h)}_{\text{訓練誤差}} + \underbrace{2\hat{\mathfrak{R}}_S(\mathcal{H})}_{\mathcal{H} \text{ の複雑さ}} + \underbrace{3\sqrt{\frac{\log(2/\delta)}{2m}}}_{S \text{ の選択による確率的揺らぎ}}$$

- $\hat{\mathfrak{R}}_S(\mathcal{H})$ が小さい $\Rightarrow$ 第2項 $\downarrow$ ，第1項 $\uparrow$
- サンプル数 m が小さい $\Rightarrow$ 第2項 $\downarrow$ ，第3項 $\uparrow$.

学習問題の「難しさ」は、 $\mathcal{H}$ の複雑さと データ数 m のバランスで決まる。

まとめ：学習問題の難しさ

- 学習問題の「難しさ」は「分布 $\mathcal{D}$ + 仮説集合 $\mathcal{H}$ 」で決まる.
- **PAC 学習**は, この難しさを (ε, δ, m) の形で定量化する枠組み.

概念	何を測るか
仮説集合 $\mathcal{H}$	アルゴリズムが選べる関数の集合
汎化誤差 $L_{\mathcal{D}}(h)$	未知データに対する真の誤差
サンプル複雑度 $m_{\mathcal{H}}(\varepsilon, \delta)$	PAC 学習に必要なデータ数
Rademacher 複雑度 $\hat{\mathfrak{R}}_S(\mathcal{H})$	$\mathcal{H}$ の表現力 (ランダム適合性)

Rademacher複雑度の制御 → 関数クラスの制限・**正則化**

演習：Rademacher 複雑度の計算

課題1：仮説集合の作成 ($m = 10, B \in \{1, 3, 5\}$)

- 制限された整数ベクトル集合 $\mathbb{Z}_{\leq B}^m = \{-B, -B + 1, \dots, B - 1, B\}^m$ から, ランダムに16個サンプリングし, W を構成する
- 線形仮説集合 $\mathcal{H}_{B,W} = \{f_w(x) := \langle w, x \rangle \mid w \in W\}$ を定める
- 以上を繰り返し, 各 B に対し, 様々な線形仮説集合を作る.

課題2：Rademacher 複雑度関数の実装

- 上記の仮説集合に対してRademacher複雑度を計算する関数を実装.
- 有限なので, 各 σ に対し $|\mathcal{H}_{B,W}| = 16$ 個の仮説を全探索して最大値を取ればよい.

課題3：プロット

- 縦軸Rademacher複雑度, 横軸 B のプロットを作成せよ. 各 B に対して様々な仮説集合を作っているはずなので箱ひげ図で表現せよ.

課題

- 演習をMoodleで提出（IPython Notebook形式）.

補足：古典的バイアス・バリアンズ分解

古典的バイアス・バリエンス分解（設定）

回帰の**二乗誤差**で典型的に紹介される分解. 本講義の近似誤差／推定誤差分解とは**別物**（後で比較）.

設定

- 真の関数 f^* が存在し, データは $y = f^*(x) + \epsilon$ (ϵ は平均 0 の雑音).
- 訓練データセット $S = \{(x_i, y_i)\}_{i=1}^m$ は, 真の分布 $\mathcal{D}$ から m 点 i.i.d. に取った**確率変数**.
- 学習結果 $\hat{f}(\cdot; S)$ は S ごとに変わる.

「平均的な予測」

$$\bar{f}(x) := \mathbb{E}_S [\hat{f}(x; S)]$$

古典的バイアスとバリエーション

$$\text{Bias}(x) = \bar{f}(x) - f^*(x), \quad \text{Var}(x) = \mathbb{E}_S [(\hat{f}(x; S) - \bar{f}(x))^2]$$

二乗誤差の分解（恒等式）

$$\mathbb{E}_S [(\hat{f}(x; S) - f^*(x))^2] = \underbrace{\text{Bias}(x)^2}_{\text{系統的なズレ}} + \underbrace{\text{Var}(x)}_{S \text{ ごとのブレ}}$$

- **Bias** : 並行宇宙（さまざまな S ）の平均予測が真の関数 f^* からどれだけズレるか.
⇒ 仮説集合 $\mathcal{H}$ が f^* を表現しきれない系統的偏り.
- **Variance** : 訓練データを取り直したときの予測のブレ.
⇒ $\mathcal{H}$ が過敏で, S の違いに大きく反応する度合い.

古典 vs 本講義 (PAC)

想定設定	回帰 + 二乗損失	一般の損失
基準とする関数	真の関数 f^*	$\mathcal{H}$ 内の 最良関数 $h^* = \arg \min_{h \in \mathcal{H}} L_{\mathcal{D}}(h)$
訓練データ S の扱い	確率変数 (並行宇宙で平均)	1 つの固定された S
バイアス	$\bar{f}(x) - f^*(x)$	$L_{\mathcal{D}}(h^*)$ (近似誤差)
バリエーション	$\mathbb{E}_S[(\hat{f} - \bar{f})^2]$	$L_{\mathcal{D}}(h_S) - L_{\mathcal{D}}(h^*)$ (推定誤差)

共通点：いずれも「 $\mathcal{H}$ の表現力」と「有限データへの適応」のトレードオフ。
⇒ 用語は似ているが**定義は別物**。混同しないこと。

*二乗損失かつ $\mathcal{H}$ への射影が学習の平均と一致する設定では、 $\mathbb{E}_x[\text{Bias}(x)^2]$ が近似誤差 (から雑音項を引いたもの) に対応する、という意味では繋がっている。

