

2026年度

機械学習演習

第8回：正則化

計良 宥志

本日の内容

1. 復習：バイアス・バリエンス分解, Rademacher 複雑度
2. 正則化： L^p ペナルティと仮説集合の制限
3. 理論： L_2 制約下の汎化バウンド
4. 具体例：Ridge 回帰（最小二乗 + L_2 正則化）
5. 演習（理論）：Ridge 回帰の閉形式解を導出する
6. 演習（実装）： λ と L_2 / L_1 正則化の比較

1. 復習

バイアス・バリエンス分解（再掲）

直感

- $\mathcal{H}$ が複雑 $\Rightarrow L_{\mathcal{D}}$ を下げる候補が増える（**良い**）.
- 同時に, L_S は小さいが $L_{\mathcal{D}}$ は大きい関数も含みやすい（**悪い**）.

$\mathcal{H}$ における最良仮説 $h^* = \arg \min_{h \in \mathcal{H}} L_{\mathcal{D}}(h)$ に関して,

$$L_{\mathcal{D}}(h_S) = \underbrace{L_{\mathcal{D}}(h^*)}_{\text{近似誤差}} + \underbrace{L_{\mathcal{D}}(h_S) - L_{\mathcal{D}}(h^*)}_{\text{推定誤差}}$$

$\mathcal{H}$ を大きく $\Rightarrow$ **近似誤差** $\downarrow$ / **推定誤差** $\uparrow$ のトレードオフ.

Rademacher 複雑度 (再掲)

訓練データ $S = \{x_1, \dots, x_m\}$, Rademacher 変数 $\sigma_i \stackrel{\text{i.i.d.}}{\sim} \text{Unif}\{-1, +1\}$:

$$\hat{\mathfrak{R}}_S(\mathcal{H}) = \mathbb{E}_\sigma \left[\sup_{h \in \mathcal{H}} \frac{1}{m} \sum_{i=1}^m \sigma_i h(x_i) \right]$$

汎化バウンド (確率 $\geq 1 - \delta$ で任意の $h \in \mathcal{H}$) :

$$L_{\mathcal{D}}(h) \leq L_S(h) + 2 \hat{\mathfrak{R}}_S(\mathcal{H}) + 3 \sqrt{\frac{\log(2/\delta)}{2m}}$$

Rademacher 複雑度と「関数の大きさ」

$$\hat{\mathfrak{R}}_S(\mathcal{H}) = \mathbb{E}_\sigma \left[\sup_{h \in \mathcal{H}} \frac{1}{m} \sum_{i=1}^m \sigma_i h(x_i) \right]$$

$\sigma_i h(x_i)$ は $|h(x_i)|$ が大きく、かつ符号が σ_i と一致すると大きい。

- $|h(x_i)|$ が小さい $\Rightarrow$ どんな σ でも $\sigma_i h(x_i)$ は小さい $\Rightarrow$ **複雑度** $\downarrow$
- $|h(x_i)|$ が大きい $\Rightarrow$ ランダムな σ にも強く align できる $\Rightarrow$ **複雑度** $\uparrow$

線形仮説 $h_w(x) = \langle w, x \rangle$ のとき、Cauchy-Schwarz より $|h_w(x_i)| \leq \|w\|_2 \|x_i\|_2$.

$\|w\|$ を小さく抑える $\Rightarrow$ 出力 $|h_w(x_i)|$ が抑えられる $\Rightarrow \hat{\mathfrak{R}}_S(\mathcal{H})$ が下がる.

2. 正則化

正則化付き目的関数

経験損失最小化（前回まで）：

$$\min_w \frac{1}{m} \sum_{i=1}^m \ell(y_i, f(x_i; w))$$

正則化＝損失に **ペナルティ項** $\Omega(w)$ を加える：


$$\underbrace{\min_w \frac{1}{m} \sum_{i=1}^m \ell(y_i, f(x_i; w))}_{\text{データへの適合}} + \underbrace{\lambda \Omega(w)}_{\text{複雑さへの罰則}}$$

- $\lambda \geq 0$: **正則化係数**（大きいほど罰則が強い）.
- $\Omega(w) = \|w\|_p^p$ など : **L^p 正則化**.


L^p ノルム

$$\|w\|_p = \left(\sum_{j=1}^n |w_j|^p \right)^{1/p}$$


代表的な例



$\|w\|_2 \leq 1$ (disk)



$\|w\|_1 \leq 1$ (diamond)



$\|w\|_\infty \leq 1$ (square)

制約として見る正則化

ペナルティ形式と**制約形式**は双対：

$$\min_w L_S(w) + \lambda \|w\|_2^2 \iff \min_w L_S(w) \quad \text{s.t.} \quad \|w\|_2 \leq B$$

- ペナルティ：複雑さに**罰則**を課す.
- 制約： $\|w\|$ に**上限** B を設ける.

正則化 = 仮説集合 $\mathcal{H}$ を「重みの大きさを制限した部分集合」に絞ること.
⇒ Rademacher 複雑度（第2項）を下げ, **推定誤差** ↓（その代わり近似誤差 ↑ の可能性）.

3. L_2 制約下の汎化バウンド

L_2 制約した線形仮説集合

仮説集合 (L_2 球で制限) :

$$\mathcal{H}_B = \{ x \mapsto \langle w, x \rangle \mid \|w\|_2 \leq B \}$$

Rademacher 複雑度の上界 ($R = \max_i \|x_i\|_2$) :

$$\hat{\mathfrak{R}}_S(\mathcal{H}_B) \leq \frac{B R}{\sqrt{m}}$$

汎化バウンド (確率 $\geq 1 - \delta$ で任意の $h \in \mathcal{H}_B$) :

$$L_{\mathcal{D}}(h) \leq L_S(h) + \frac{2BR}{\sqrt{m}} + 3\sqrt{\frac{\log(2/\delta)}{2m}}$$

証明 (1/2) : $\hat{\mathfrak{R}}_S(\mathcal{H}_B)$ の上界

Step 1 Cauchy-Schwarz不等式 で $\sup$ を計算 :

$$\sup_{\|w\| \leq B} \frac{1}{m} \sum_i \sigma_i \langle w, x_i \rangle = \frac{B}{m} \left\| \sum_i \sigma_i x_i \right\|_2$$

(等号 : w が $\sum_i \sigma_i x_i$ と同方向)

Step 2 σ_i について期待値をとる ($\mathbb{E}[\sigma_i \sigma_j] = \delta_{ij}$) :

$$\mathbb{E}_\sigma \left\| \sum_i \sigma_i x_i \right\|_2^2 = \sum_i \|x_i\|_2^2 \leq mR^2$$

Jensen不等式 より $\mathbb{E}\|v\| \leq \sqrt{\mathbb{E}\|v\|^2} \leq R\sqrt{m}$.

証明 (2/2) : 汎化バウンドへ

Step 3 Step 1-2 より

$$\hat{\mathfrak{R}}_S(\mathcal{H}_B) = \mathbb{E}_\sigma \left[\sup_{\|w\| \leq B} \dots \right] \leq \frac{B}{m} \cdot R\sqrt{m} = \frac{BR}{\sqrt{m}}.$$

Step 4 前回の Rademacher 汎化バウンドに代入：

$$L_{\mathcal{D}}(h) \leq L_S(h) + 2\hat{\mathfrak{R}}_S(\mathcal{H}_B) + 3\sqrt{\frac{\log(2/\delta)}{2m}} \leq L_S(h) + \frac{2BR}{\sqrt{m}} + 3\sqrt{\frac{\log(2/\delta)}{2m}}. \quad \blacksquare$$

- B ($\|w\|$ の上限) を小さく $\Rightarrow$ 第2項 $\downarrow \Rightarrow$ 汎化しやすい

4. Ridge 回帰

最小二乗法 + L_2 正則化

線形回帰 $\mathbf{y} \in \mathbb{R}^m$, $\mathbf{X} \in \mathbb{R}^{m \times n}$ (m サンプル, n 特徴).

Ridge 回帰 (L_2 正則化付き最小二乗法) :

$$\min_{\mathbf{w}} \|\mathbf{y} - \mathbf{X}\mathbf{w}\|_2^2 + \lambda \|\mathbf{w}\|_2^2$$

- 第1項 : 訓練データへの**当てはまり** (L_S に相当).
- 第2項 : 重みを**小さく保つ** 罰則 ($\mathcal{H}_B$ への制限に相当).

閉形式解 ($\lambda > 0$) :

$$\hat{\mathbf{w}}_{\text{ridge}} = (\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^\top \mathbf{y}$$

$\lambda \mathbf{I}$ で $\mathbf{X}^\top \mathbf{X}$ の固有値 (全て非負) をそれぞれ $+\lambda$ 押し上げる ($\rightarrow$ 逆行列が必ず存在).

演習：Ridge 回帰の閉形式解

Ridge 回帰の閉形式解を示せ.

$$\hat{\mathbf{w}}_{\text{ridge}} = (\mathbf{X}^{\top} \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^{\top} \mathbf{y}$$

6. 演習

演習（実装）：正則化の効果を比較する

設定（例： `sklearn.datasets.make_regression` で $n = 100$, 特徴 $d = 30$, 有効次元 5 など）.

訓練／テストに分割し，特徴量は標準化する.

課題1： λ （`alpha`）を変える

- Ridge (L_2) と Lasso (L_1) で, $\alpha \in \{10^{-3}, 10^{-2}, \dots, 10^2\}$ 程度を変えて学習.
- 各 α について**訓練 MSE**と**テスト MSE**を記録し, α に対する曲線をプロットせよ (Ridge / Lasso で色分け).

課題2： L_2 と L_1 の係数を比較

- 同じ α （例： $\alpha = 1$ ）で Ridge と Lasso を学習.
- 係数ベクトル $\hat{\mathbf{w}}$ を棒グラフ等で可視化し, L_1 はスパース (0 が多い), L_2 は全体が小さく縮むことを確認せよ.

課題

- **演習（実装）** を Moodle で提出（IPython Notebook 形式）.
- 上記 2 つのプロットと観察メモを含めること.
- 理論演習（閉形式解の導出）は授業内で取り組む（提出不要）.

