

2026年度

機械学習演習

第9回：教師なし学習とスペクトルクラスタリング

計良 宥志

本日の内容

1. 教師なし学習とクラスタリング
2. K-means の限界
3. グラフ・affinity 行列・カーネル
4. グラフ・ラプラシアンと固有値分解
5. スペクトルクラスタリングの手順
6. 演習：非球状データでのクラスタリング比較

1. 教師なし学習

教師あり vs 教師なし

データ	$\mathcal{D} = \{(x_i, y_i)\}$	$\mathcal{D} = \{x_1, \dots, x_n\}$
目的	$x \mapsto y$ を学習	データの 構造 を発見
例	回帰, 分類	クラスタリング, 次元削減

クラスタリング: 類似したを同じグループ（クラスタ）にまとめる.


類似度の定義（= 点間の距離の定義）が必要.

K-meansと限界


K-means : K 個の中心 μ_k を持ち, 各点を最も近い中心に割り当てる.

$$\min_{\{\mu_k\}, \{C_k\}} \sum_{k=1}^K \sum_{x_i \in C_k} \|x_i - \mu_k\|_2^2$$

- 仮定 : クラスタは**球状** (L_2 距離ベース).



K-means (fails)




Spectral (works)

三日月型など非球状クラスタでは K-means は**うまくいかない**ことが多い.

2. スペクトルクラスタリング

データをグラフとして見る

考え方：各データ点 x_i を**頂点**，類似度が高い点同士を**辺**で結ぶ。



- 同じクラスタ内の点 ⇒ **強く結ばれる**（辺の重みが大い）
- 異なるクラスタ間 ⇒ **弱く結ばれる**

⇒ クラスタリングは「**グラフを K 個のまとまりに分割する**」問題に変換できる。

Affinity 行列（類似度行列） W

n 点のデータに対し，対称な**affinity 行列** $W \in \mathbb{R}^{n \times n}$ を定義：

$$W_{ij} = W_{ji} \geq 0 \quad (x_i \text{ と } x_j \text{ の類似度})$$

例1： k 近傍グラフ 近い k 点だけを辺で結ぶ（それ以外は 0）.

例2：ガウス（RBF）カーネル（教師ありで学んだカーネルと同型）

$$W_{ij} = \exp\left(-\frac{\|x_i - x_j\|^2}{2\sigma^2}\right)$$

- σ が小さい $\Rightarrow$ **近い点だけ**強く結ぶ. σ が大きい $\Rightarrow$ **遠い点も**結びやすい.

カーネルが非線形な構造もグラフに反映.

クラスタリング = グラフカット最小化

グラフを良い感じに 2 つの塊A, Bに分けたい.

→ **グラフカット** (切れる辺の重みの合計) が最小になるよう分ける.

グラフの頂点集合を V とすると,

$$\min_{A,B} \sum_{i \in A, j \in B} W_{ij}, \quad (V = A \cup B, A \cap B = \emptyset)$$

- 素朴な分割方法は 2^n 通りで膨大.
- 実は**グラフラプラシアン**の固有値問題で解決.

グラフラプラシアン

「良い分割」の直感： W_{ij} が大きい (i, j) を同グループに.

次数行列 $D = \text{diag}(d_1, \dots, d_n)$, ただし $d_i = \sum_j W_{ij}$ (頂点 i の結合の総量).

グラフ・ラプラシアン：

$$L = D - W$$

グラフの2分割を $v = (v_1, \dots, v_n) \in \{1, -1\}^n$ で考える.

実は, L の固有ベクトルが良い v を与える！

グラフ・ラプラシ안의性質

任意の $v \in \mathbb{R}^n$ に対して

$$v^\top L v = \frac{1}{2} \sum_{i,j=1}^n W_{ij} (v_i - v_j)^2$$

この $v^\top L v$ の最小化は,

接続の強い (i, j) ($=W_{ij}$ が大きい (i, j)) で, $v_i = v_j$ であるべき.

という直感を実現する.

演習

対称行列 $W \in \mathbb{R}^{n \times n}$ が以下を満たすことを示せ.

任意の $v \in \mathbb{R}^n$ に対して

$$v^\top L v = \frac{1}{2} \sum_{i,j=1}^n W_{ij} (v_i - v_j)^2$$

グラフカット最小化

2分割 $v \in \{+1, -1\}^n$ に対し, i, j が同クラスタなら $(v_i - v_j)^2 = 0$, 異クラスタなら $(v_i - v_j)^2 = 4$.

$$v^\top L v = \frac{1}{2} \sum_{i,j} W_{ij} (v_i - v_j)^2 = 2 \sum_{i \in A, j \in B} W_{ij} = 4 \text{cut}(A, B)$$

カット最小化 $\iff v^\top L v$ の最小化. 分割探索が行列 L の最小化になった.

自明解の回避と固有ベクトルへの緩和

離散ベクトル $v \in \{\pm 1\}^n$ の最適化は大変なので、実数緩和する.

$$\min_v v^\top L v, \quad \text{s.t. } \|v\|^2 = n, v^\top \mathbf{1} = 0.$$

- ノルム制約は別に $\|v\|^2 = 1$ でもOK.
- 直交制約は、自明解 $v = \mathbf{1}$ (全点を同じクラス) で $v^\top L v = 0$ を避けるため.

つまり、 $v^\top L v$ の2番目に小さい固有値の固有ベクトルが非自明なカットを与える.

- u_2 の各成分の**符号**で2クラスタに分ける.
- K クラスタなら小さい方から K 個の固有ベクトルを使う.

スペクトルクラスタリングの手順

クラスタ数 K を指定し，次を行う．

1. affinity 行列 W を構成（例：RBF カーネル）．
2. ラプラシアン $L = D - W$ を計算．
3. L の小さい固有値から K 個の固有ベクトル $u_1, \dots, u_K$ を求める．
4. 各点 i を $(u_1(i), \dots, u_K(i)) \in \mathbb{R}^K$ に埋め込む．
5. 埋め込んだ点を **K-means** でクラスタリング．

核心：元空間では難しいクラスタリングを， $v^\top L v$ を小さくする固有ベクトルの空間（＝分離しやすい空間）へ写してから K-means．

3. 演習

演習：スペクトルクラスタリング

課題1：12頂点のグラフの2分割を考える。グラフが接続のない K 個の部分グラフからなる様に隣接行列 W を適当に定義せよ。

1. グラフラプラシアン L を計算し、0固有値がちょうど K 個になることを確認せよ。
2. 行列 W の値が0である部分に小さな正のノイズを加えよ。その際 W の対称性が保たれる様に注意するべきだが、それを怠った場合で、 W の固有値を計算して見よ
3. 対称性を保つように $W \leftarrow 1/2W + 1/2W^T$ で隣接行列を再定義する。グラフラプラシアン L の固有値を計算し、横軸が固有値のインデックス、縦軸が固有値の値でプロットせよ。

演習：スペクトルクラスタリング

課題2 `sklearn.datasets.make_moons` ($n = 200$, `noise=0.1` 程度). に対してスペクトラルクラスタリングを行い, うまく分割できることを確認せよ.

- RBFカーネルにより類似度行列 W を定義し, スペクトラルクラスタリングを行え. クラスタリング結果は元の 2 次元空間にクラスタ割当を色分けしてプロットせよ. RBFカーネルのパラメータ σ を変えた場合を比較せよ.
- K-meansクラスタリングは, `sklearn` の `KMeans(n_clusters=2)` を用いて良い.

課題

- 演習を Moodle で提出 (IPython Notebook 形式).

