

2026年度

機械学習演習

第13回：モデルフリー強化学習（TD学習・Q学習）

計良 宥志

本日の内容

1. 復習：価値関数とベルマン方程式（期待値記法で簡潔に）
2. モデルあり → モデルフリー：遷移 P が未知でも学びたい
3. 価値推定 (Prediction)：モンテカルロ (MC) と TD 学習
4. 制御 (Control)：SARSA・Q学習, on-policy / off-policy
5. 演習：TD 更新の手計算 / Cliff Walking の実装

前回（第12回）はモデル既知の**動的計画法**（価値反復・方策反復）。今回は P を知らずに**経験（サンプル）**から価値・方策を学ぶ。

1. 復習：価値関数とベルマン方程式

復習：リターンと価値関数

リターン（時刻 t 以降の割引報酬和）：

$$G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \cdots = R_{t+1} + \gamma G_{t+1}$$

方策 π のもとでの**価値関数**は、リターンの期待値：

$$V^\pi(s) = \mathbb{E}_\pi[G_t \mid S_t = s], \quad Q^\pi(s, a) = \mathbb{E}_\pi[G_t \mid S_t = s, A_t = a]$$

V^π ：状態の良さ， Q^π ：状態で行動を取る良さ． 目標は期待リターンを最大化する π^* ．

記法：期待値をどの確率で取るか明示する

以降、**何についての平均か**を期待値の添字で表す：

$\mathbb{E}_{a \sim \pi(\cdot | s)}[\cdot]$ 行動を方策から, $\mathbb{E}_{s' \sim P(\cdot | s, a)}[\cdot]$ 次状態を遷移から

これを使うと, $\sum_a \pi(a | s) \sum_{s'} P(s' | s, a) [\dots]$ という**二重和**を

$$\mathbb{E}_{a \sim \pi, s' \sim P}[\dots]$$

と簡潔に書ける（中身は同じ）．期待値の**入れ子**で「まず a , 次に s' 」という流れも表せる．

復習：状態価値のベルマン方程式（期待値記法）

リターンの分解 $G_t = R_{t+1} + \gamma G_{t+1}$ を代入し，途中の a, s' で期待値を入れ子に展開する：

$$\begin{aligned} V^\pi(s) &= \mathbb{E}_\pi[R_{t+1} + \gamma G_{t+1} \mid S_t = s] \\ &= \mathbb{E}_{a \sim \pi(\cdot|s)} \mathbb{E}_{s' \sim P(\cdot|s,a)} \left[r(s, a, s') + \gamma \underbrace{\mathbb{E}_\pi[G_{t+1} \mid S_{t+1} = s']}_{= V^\pi(s')} \right] \\ &= \mathbb{E}_{a \sim \pi, s' \sim P} [r(s, a, s') + \gamma V^\pi(s')] \end{aligned}$$

マルコフ性より $\mathbb{E}_\pi[G_{t+1} \mid S_{t+1} = s'] = V^\pi(s')$. 「今の報酬 + 割引した次の価値」の期待値.

復習：行動価値のベルマン方程式（期待値記法）

Q^π では最初の a は固定. 次状態 s' , さらに次の行動 a' で期待値を取る:

$$\begin{aligned} Q^\pi(s, a) &= \mathbb{E}_{s' \sim P(\cdot | s, a)} \left[r(s, a, s') + \underbrace{\gamma \mathbb{E}_{a' \sim \pi(\cdot | s')} [Q^\pi(s', a')]}_{= V^\pi(s')} \right] \\ &= \mathbb{E}_{s' \sim P, a' \sim \pi} [r(s, a, s') + \gamma Q^\pi(s', a')] \end{aligned}$$

V と Q は $V^\pi(s) = \mathbb{E}_{a \sim \pi} [Q^\pi(s, a)]$, $Q^\pi(s, a) = \mathbb{E}_{s' \sim P} [r + \gamma V^\pi(s')]$ で行き来できる.

復習：ベルマン最適方程式（期待値記法）

最適では、方策による平均 $\mathbb{E}_{a \sim \pi}$ が「最良の行動を選ぶ」 $\max_a$ に変わる：

$$V^*(s) = \max_a \mathbb{E}_{s' \sim P(\cdot|s,a)} [r(s, a, s') + \gamma V^*(s')]]$$

$$Q^*(s, a) = \mathbb{E}_{s' \sim P(\cdot|s,a)} [r(s, a, s') + \gamma \max_{a'} Q^*(s', a')]]$$

Q^* が分かれば最適方策は $\pi^*(s) = \arg \max_a Q^*(s, a)$ （モデル不要でテーブルを引くだけ）.

復習まとめ：4つのベルマン方程式

	評価（方策 π 固定）	最適
状態 価値	$V^\pi(s) = \mathbb{E}_{a \sim \pi, s' \sim P}[r + \gamma V^\pi(s')]$	$V^*(s) = \max_a \mathbb{E}_{s' \sim P}[r + \gamma V^*(s')]$
行動 価値	$Q^\pi(s, a) = \mathbb{E}_{s' \sim P, a' \sim \pi}[r + \gamma Q^\pi(s', a')]$	$Q^*(s, a) = \mathbb{E}_{s' \sim P}[r + \gamma \max_{a'} Q^*(s', a')]$

共通の形： 価値 = $\mathbb{E}[\text{即時報酬} + \gamma \times (\text{次の価値})]$.
動的計画法は、この期待値 $\mathbb{E}_{s' \sim P}$ を**モデル P で計算**して反復した。

2. モデルあり → モデルフリー

動機：遷移 P が分からないと期待値が計算できない

ベルマン方程式の右辺は、必ず**次状態に関する期待値** $\mathbb{E}_{s' \sim P(\cdot | s, a)}[\dots]$ を含む。

- 動的計画法（前回）： $P(s' | s, a)$ が**既知**なので、この期待値を和で明示的に計算できた。
- しかし現実では P を事前に知らないことが多い（ゲームのルール・ロボット・市場…）。

核心のアイデア：期待値 $\mathbb{E}_{s' \sim P}[\dots]$ を、**実際に観測したサンプル** (s, a, r, s') で置き換える（サンプル近似）。

- これが**モデルフリー**学習。次節で MC と TD の 2 つの近似を見る。

(以降：MC・TD・SARSA・Q学習・演習)