

2026年度

機械学習演習

第14回：モデルフリー強化学習（TD学習・Q学習）

計良 宥志

本日の内容

1. モデルあり → モデルフリー：遷移 P が未知でも学びたい
2. 価値推定 (Prediction)：モンテカルロ (MC) と TD 学習
3. 制御 (Control)：SARSA・Q学習, on-policy / off-policy
4. 演習：TD 更新の手計算／Cliff Walking の実装

前回（第13回）はベルマン方程式を期待値記法で整理した。今回はその右辺の期待値を P を知らずにサンプルで置き換えて、価値・方策を学ぶ。

復習：ベルマン方程式（前回）

	評価（方策 π 固定）	最適
状態 価値	$V^\pi(s) = \mathbb{E}_{a \sim \pi, s' \sim P}[r + \gamma V^\pi(s')]$	$V^*(s) = \max_a \mathbb{E}_{s' \sim P}[r + \gamma V^*(s')]$
行動 価値	$Q^\pi(s, a) = \mathbb{E}_{s' \sim P, a' \sim \pi}[r + \gamma Q^\pi(s', a')]$	$Q^*(s, a) = \mathbb{E}_{s' \sim P}[r + \gamma \max_{a'} Q^*(s', a')]$

共通の形： 価値 = $\mathbb{E}[\text{即時報酬} + \gamma \times (\text{次の価値})]$.

右辺は必ず**次状態に関する期待値** $\mathbb{E}_{s' \sim P}$ を含む.

1. モデルあり → モデルフリー

動機：遷移 P が分からないと期待値が計算できない

ベルマン方程式の右辺は、必ず**次状態に関する期待値** $\mathbb{E}_{s' \sim P(\cdot | s, a)}[\dots]$ を含む。

- 動的計画法（第12回）： $P(s' | s, a)$ が**既知**なので、期待値を和で計算できた。
- 現実では P を事前に知らないことが多い（ゲーム・ロボット・市場など）。

核心のアイデア：期待値 $\mathbb{E}_{s' \sim P}[\dots]$ を、**実際に観測したサンプル** (s, a, r, s') で置き換える（サンプル近似）。

- これが**モデルフリー**学習。次節で MC と TD の 2 つの近似を見る。

エピソードとサンプル

環境と方策 π を実際に動かすと、**軌跡**（エピソード）が得られる：

$$S_0, A_0, R_1, S_1, A_1, R_2, S_2, \dots$$

- 遷移 1 歩分の組 (s, a, r, s') が、 $\mathbb{E}$ の中身の**1 サンプル**.
- P や R の式を知らなくても、**動かせば s' と r は観測できる**.

「終端までの 1 回の試行」を**エピソード**と呼ぶ（迷路ならゴール到達まで）.

2. 価値推定 (Prediction)

核心：期待値はサンプル平均で推定する

推定したいのは期待値 $V^\pi(s) = \mathbb{E}_\pi[G_t \mid S_t = s]$.

期待値の素朴な推定は**サンプル平均**. 平均は次の**逐次更新**でも書ける：

$$\mu_k = \mu_{k-1} + \frac{1}{k} (x_k - \mu_{k-1})$$

$\frac{1}{k}$ を**学習率** α に一般化すると，価値推定の共通形が得られる：

$$V(s) \leftarrow V(s) + \alpha (\text{目標} - V(s))$$

以降，添字なしの V (や Q) は学習中の**推定値**を表し，真の V^π 等と区別する.

「**目標 (target)**」に何を使うかで MC と TD が分かれる. α は新しい情報の取り込み具合.

MC（モンテカルロ）：実測リターンを目標にする

エピソードを終端まで走らせ、実際に得た**リターン** G_t を目標にする：

$$V(s_t) \leftarrow V(s_t) + \alpha (G_t - V(s_t))$$

- G_t は $V^\pi(s) = \mathbb{E}_\pi[G_t \mid S_t = s]$ の**不偏なサンプル** → バイアスなし.
- 弱み：**終端まで待つ**必要がある／ G_t は多ステップの和なので**分散が大きい**／終わらない継続タスクに使えない.

MC は「試験が全部終わってから結果を見て反省する」学び方.

TD(0)：ベルマン方程式をサンプルで置き換える

ベルマン方程式 $V^\pi(s) = \mathbb{E}_{a \sim \pi, s' \sim P}[r + \gamma V^\pi(s')]$ の右辺を、
観測した 1 遷移 (s, r, s') の**1 サンプル** $r + \gamma V(s')$ で置き換える：

$$V(s) \leftarrow V(s) + \alpha \underbrace{\left[r + \gamma V(s') - V(s) \right]}_{\text{TD 誤差 } \delta}$$

- **TD 目標**： $r + \gamma V(s')$ (MC の G_t に相当する 1 ステップ版).
- **ブートストラップ**： 不正確な推定値 $V(s')$ で $V(s)$ を更新 (推定で推定を改善).
- 終端を待たず, 1 歩ごとに**オンライン更新**できる.

TD 誤差 δ の意味

$$\delta = \underbrace{\left[r + \gamma V(s') \right]}_{\text{1 歩進んで得た新しい見積り}} - \underbrace{V(s)}_{\text{今の見積り}}$$

- δ は**予測のズレ**. これが学習を駆動する量.
- $\delta > 0$: 今の $V(s)$ は**過小評価** $\rightarrow$ 上げる.
- $\delta < 0$: 今の $V(s)$ は**過大評価** $\rightarrow$ 下げる.

「1 問解くごとに予測とのズレで即修正する」学び方. 終端を待たない.

MC と TD の対比

	MC	TD(0)
目標	実測 G_t (真値のサンプル)	$r + \gamma V(s')$ (推定を含む)
バイアス	なし	あり ($V(s')$ が不正確なうち)
分散	大 (多ステップの積み重なり)	小 (1 ステップのみ)
更新	終端後	逐次 (オンライン)

トレードオフ：待って正確 (MC) か 速いが近似 (TD) か (中間形は付録).
どちらも, α を適切に減衰させれば真の V^π に収束する (確率的近似).

3. 制御 (Control)

予測から制御へ：なぜ Q を学ぶか

制御 = 最適方策 π^* を得ること（価値推定と方策改善を繰り返す）.

状態価値 $V(s)$ だけでは行動を選べない：

$$\pi^*(s) = \arg \max_a \mathbb{E}_{s' \sim P}[r + \gamma V^*(s')] \quad \Rightarrow \quad P \text{ が 必要}$$

行動価値 $Q(s, a)$ を直接学べば，モデル不要で行動を選べる：

$$\pi^*(s) = \arg \max_a Q^*(s, a) \quad \Rightarrow \quad Q \text{ テーブルを引くだけ}$$

方針： Q を TD で推定しつつ，その Q で方策を改善する（ ϵ -greedy で探索）.

探索と活用： ϵ -greedy

制御では、データを集めるために実際に行動を選ぶ方策が必要.

「今のベスト」の活用と、別の行動の探索の両方を含める：

$$a = \begin{cases} \arg \max_a Q(s, a) & \text{確率 } 1 - \epsilon \quad (\text{活用 exploitation}) \\ \text{ランダムな行動} & \text{確率 } \epsilon \quad (\text{探索 exploration}) \end{cases}$$

- 探索が少なすぎ → 未知の良い行動を見つけられず局所解.
- 探索が多すぎ → 既知の良い行動を使えず報酬が低いまま.

この行動選択則を **ϵ -greedy 方策**と呼ぶ. 実践では ϵ を徐々に減衰させる.

TD 制御の共通構造

登場する 2 つの方策と、学習対象を区別する：

- **挙動方策** b ：実際に行動してデータ (s, a, r, s') を集める方策（前頁の ϵ -greedy）.
- **ターゲット方策** π ：価値を評価・改善したい方策.
- $Q(s, a)$ （添字なし）：学習中の**推定値**. 真の価値関数 $Q^\pi \cdot Q^*$ と区別する.

更新式はどの手法も共通で、

$$Q(s, a) \leftarrow Q(s, a) + \alpha \left[\underbrace{r + \gamma \times (\text{次行動の価値})}_{\text{TD 目標}} - Q(s, a) \right]$$

手法の違いは「次行動の価値」 = **どのターゲット方策で評価するか**だけ.
 $\pi = b$ なら **on-policy**, $\pi \neq b$ なら **off-policy**.

SARSA (on-policy)

- 挙動方策 : $b = \varepsilon$ -greedy.
- ターゲット方策 : $\pi = b$ (実際に動いている方策そのもの) → **on-policy**.
- 次行動の価値 : 実際に選んだ $a' \sim b(\cdot \mid s')$ の $Q(s', a')$ をそのまま使う :

$$Q(s, a) \leftarrow Q(s, a) + \alpha [r + \gamma Q(s', a') - Q(s, a)]$$

- a' は π 自身からのサンプルなので, 補正なしでベルマン方程式 $Q^\pi(s, a) = \mathbb{E}_{s' \sim P, a' \sim \pi} [r + \gamma Q^\pi(s', a')]$ のサンプル近似になる.
- 探索中の「危険な行動の結果」も Q に反映される → **安全寄り**.

名前の由来 : 5 つ組 (S, A, R, S', A') を使うから.

Q学習 (off-policy)

- 挙動方策 : $b = \varepsilon$ -greedy (探索できれば何でもよい).
- ターゲット方策 : $\pi = \text{greedy}$ (常に最善の行動) $\rightarrow \pi \neq b$ なので **off-policy**.
- 次行動の価値 : greedy のもとでの価値は $\max_{a'} Q(s', a')$ と直接計算できる :

$$Q(s, a) \leftarrow Q(s, a) + \alpha \left[r + \gamma \max_{a'} Q(s', a') - Q(s, a) \right]$$

- ベルマン最適方程式 $Q^*(s, a) = \mathbb{E}_{s' \sim P} [r + \gamma \max_{a'} Q^*(s', a')]$ のサンプル近似.
- 実際の a' は更新に関係ない $\rightarrow$ 探索は自由にしつつ, 最適 Q^* を直接ねらう.
- 収束保証あり (Watkins & Dayan, 1992).

on-policy と off-policy の違い

共通構造は同じで、違いは**ターゲット方策**（＝次行動の価値の決め方）だけ：

	SARSA	Q学習
挙動方策 b	ε -greedy	ε -greedy
ターゲット方策 π	b と同じ	greedy
TD 目標	$r + \gamma Q(s', a'), a' \sim b$	$r + \gamma \max_{a'} Q(s', a')$
収束先	現在の方策の Q^π	最適 Q^*
性質	on-policy（安全寄り）	off-policy（最適を追求）

Cliff Walking：SARSA は崖を避ける安全ルート，Q学習は崖際の最短ルート．

4. 演習

まとめ：TD(0)・SARSA・Q学習の更新式

手法	目的	更新式
TD(0)	V^π の推定	$V(s) \leftarrow V(s) + \alpha [r + \gamma V(s') - V(s)]$
SARSA	制御 (on-policy)	$Q(s, a) \leftarrow Q(s, a) + \alpha [r + \gamma Q(s', a') - Q(s, a)]$
Q学習	制御 (off-policy)	$Q(s, a) \leftarrow Q(s, a) + \alpha [r + \gamma \max_{a'} Q(s', a') - Q(s, a)]$

- 共通形：更新後 = 現在値 + $\alpha \times$ TD 誤差 (TD 誤差 = TD 目標 - 現在値).
- 違いは **TD 目標の次行動の価値**：SARSA は実際に選んだ a' ，Q学習は $\max$.

次の演習1は，この3つの式に数値を代入するだけで解ける.

演習1（手計算）：TD・SARSA・Q学習の更新

いずれも $\alpha = 0.1$, $\gamma = 0.9$, $r = 1$ の 1 遷移 $s \rightarrow s'$ とする.

1. **TD(0)** : $V(s) = 2.0$, $V(s') = 3.0$. 更新後の $V(s)$ を求めよ.
2. **SARSA** : $Q(s, a) = 2.0$, 実際に選んだ次行動で $Q(s', a') = 3.0$. 更新後の $Q(s, a)$ を求めよ.
3. **Q学習** : $Q(s, a) = 2.0$, 次状態の行動価値が $Q(s', \cdot) = \{3.0, 5.0, 1.0\}$. 更新後の $Q(s, a)$ を求めよ.
4. 2 と 3 は, それぞれ **on-policy** / **off-policy** のどちらか. 理由も述べよ.

ヒント : どれも「更新後 = 現在値 + $\alpha \times$ TD 誤差」. 違いは TD 目標だけ.

計算メモ

演習2（実装）：Cliff Walking で SARSA vs Q学習

環境（ 4×12 グリッド，決定的遷移）

- 状態 S ：各マス. 左下 S がスタート，右下 G がゴール（終端）.
- 下辺の S - G 間は崖. 行動 $\mathcal{A} = \{\uparrow, \downarrow, \leftarrow, \rightarrow\}$ （枠外へは動かない）.
- 報酬 R ：1 歩ごとに -1 . 崖に入ると -100 で S に戻る. G 到達で終了.
- パラメータ： $\varepsilon = 0.1$, $\alpha = 0.5$, $\gamma = 1$.

課題

1. SARSA と Q学習で $Q(s, a)$ を学習せよ（ ε -greedy で行動）.
2. 学習後の**貪欲方策の経路**を可視化し，両者の違いを比較せよ.
3. エピソードごとの合計報酬の推移を両手法で比較せよ.

期待される観察：Q学習は崖際の最短経路，SARSA は安全な迂回経路を学ぶ.

課題

提出物

1. **演習1（手計算）**：計算用紙のスキャン（または写真）を提出。各更新式と TD 誤差を明示すること。
2. **演習2（実装）**：コードと、(a) 両手法の貪欲経路の図、(b) 報酬推移の比較図、(c) 考察（なぜ経路が違うか）。

考察のヒント：SARSA は探索(ϵ -greedy)中に崖へ落ちる結果まで Q に織り込むため、崖から離れる。Q学習は $\max$ で更新するので探索の失敗を無視し、最短（崖際）を最適とみなす。

付録

付録：全体像（発展）

DP（モデルあり） → MC / TD（モデルフリー） → 深層強化学習

- **テーブル法の限界**：状態・行動が小さく有限なときのみ（囲碁 $\sim 10^{170}$ ，画像入力，連続制御は不可）.
- **関数近似**： $Q(s, a)$ をニューラルネット等で表す.
 - value-based：**DQN**（離散行動）
 - policy-based / actor-critic：**PPO**・**SAC**（連続行動にも強い）

付録： n -step TD

TD 目標を n ステップ分の実測に伸ばす：

$$G_t^{(n)} = r_{t+1} + \gamma r_{t+2} + \cdots + \gamma^{n-1} r_{t+n} + \gamma^n V(s_{t+n})$$

- $n = 1$: TD(0) (本講義の TD).
- $n \rightarrow \infty$ (エピソード全体) : MC.
- 中間の n : バイアスと分散のトレードオフを調整.

発展：全 n -step 目標の λ 重み付け平均が **TD(λ)** (eligibility trace).